

Actividad de la semana 15(PC4)

Organización de los elementos para documentar el proceso de análisis estadístico

1. Conjunto de datos asignado

Cada estudiante recibirá un conjunto de datos ficticio (o real anonimizado) relacionado con salud. Por ejemplo:

- ❖ **Datos:** Pacientes con hipertensión (n=150). Variables: edad, sexo, IMC, PAS, colesterol, fumador, diabetes, tratamiento (A/B).
- ❖ **Objetivo del análisis:** Evaluar si el tratamiento A reduce la PAS en comparación con el B, ajustando por las demás variables.

2. Estructura de carpetas para un proyecto reproducible

El estudiante debe crear en su repositorio de GitHub la siguiente estructura:

```
proyecto_estadistico/
├─ data/
│  ├─ raw/                # Datos crudos (no modificar)
│  │   └─ pacientes.csv
│  └─ processed/          # Datos limpios (generados por script)
│     └─ pacientes_clean.csv
├─ scripts/
│  ├─ 01_limpieza.R        # Limpieza y transformación
│  ├─ 02_analisis_descriptivo.R
│  ├─ 03_modelo_regresion.R
│  └─ funciones_auxiliares.R (opcional)
├─ outputs/
│  ├─ tables/              # Tablas en formato .csv o .tex
│  ├─ figures/             # Gráficos en .png o .pdf
│  └─ reports/             # Informes en .pdf, .html, .docx
├─ README.md              # Explicación del proyecto
├─ .gitignore              # Archivos a excluir (datos sensibles, archivos temporales)
├─ LICENSE                 # Licencia (ej. MIT, CC BY)
└─ references.bib          # Bibliografía (si se usa en informes)
```

3. Ejemplo de contenido de cada archivo

README.md (formato Markdown):

```
# Análisis del efecto del tratamiento A sobre la presión arterial

**Autores:** Nombre del estudiante
**Fecha:** Julio 2026
**Objetivo:** Evaluar si el tratamiento A reduce significativamente la PAS en comparación con el tratamiento B, ajustando por edad, sexo, IMC, colesterol, tabaquismo y diabetes.

## Estructura del proyecto
- `data/raw/` : Datos originales (no modificar)
- `data/processed/` : Datos limpios generados por el script 01_limpieza.R
- `scripts/` : Código R para limpieza, análisis y gráficos
- `outputs/` : Tablas y figuras generadas

## Cómo ejecutar
1. Clonar este repositorio.
2. Abrir R y establecer el directorio de trabajo en la raíz del proyecto.
3. Ejecutar los scripts en orden numérico.
4. Los resultados se guardarán en `outputs/`.
```

```
## Paquetes requeridos
- tidyverse, ggplot2, dplyr, car, etc. (se listan con `sessionInfo()`)
```

```
## Licencia
Este proyecto está bajo licencia MIT.
```

.gitignore (ejemplo mínimo):

```
*.Rproj
.Rproj.user
.DS_Store
*.log
*.aux
*.out
*.synctex.gz
data/processed/ # si no quieres subir datos procesados (depende del caso)
```

Script de limpieza (01_limpieza.R):

```
# Leer datos
datos_raw <- read_csv("data/raw/pacientes.csv")

# Recodificar valores, manejar NAs, crear nuevas variables
datos_clean <- datos_raw %>%
  mutate(
    sexo = factor(sexo, labels = c("Hombre", "Mujer")),
    fumador = factor(fumador, labels = c("No", "Sí")),
    diabetes = factor(diabetes, labels = c("No", "Sí")),
    tratamiento = factor(tratamiento, labels = c("B", "A")),
    imc_cat = case_when(
      imc < 18.5 ~ "Bajo peso",
      imc >= 18.5 & imc < 25 ~ "Normal",
      imc >= 25 & imc < 30 ~ "Sobrepeso",
      imc >= 30 ~ "Obesidad"
    )
  ) %>%
  filter(!is.na(pas)) # eliminar PAS missing (opción justificada)

# Guardar datos limpios
write_csv(datos_clean, "data/processed/pacientes_clean.csv")
```

Script de análisis (03_modelo_regresion.R):

```
# 03_modelo_regresion.R
library(tidyverse)
library(broom)

datos <- read_csv("data/processed/pacientes_clean.csv")

# Modelo lineal: PAS ~ tratamiento + edad + sexo + imc + colesterol + fumador + diabetes
modelo <- lm(pas ~ tratamiento + edad + sexo + imc + colesterol + fumador + diabetes,
  data = datos)

# Tabla de coeficientes
tabla_coef <- tidy(modelo, conf.int = TRUE)
write_csv(tabla_coef, "outputs/tables/coeficientes.csv")
```

```
# Gráfico de coeficientes
library(ggplot2)
ggplot(tabla_coef[-1,], aes(x = estimate, y = term)) +
  geom_point() +
  geom_errorbarh(aes(xmin = conf.low, xmax = conf.high), height = 0.2) +
  geom_vline(xintercept = 0, linetype = "dashed", color = "red") +
  labs(title = "Efecto de las variables sobre la PAS",
       x = "Estimación (IC 95%)", y = "") +
  theme_minimal()
ggsave("outputs/figures/coeficientes.png", width = 6, height = 4)
```

4. Instrucciones para la actividad asincrónica (entregable)

Tarea para el estudiante:

1. **Crear un repositorio en GitHub** con el nombre `analisis_pas_apellido` (reemplazar por su apellido).
2. **Inicializar el repositorio** con un **README.md** explicativo (usar la plantilla proporcionada).
3. **Subir la estructura de carpetas** vacías o con los archivos de ejemplo.
4. **Agregar los datos** en `data/raw/` (el docente proporciona un archivo CSV).
5. **Crear los scripts** de limpieza y análisis siguiendo el orden numérico.
6. **Ejecutar los scripts** localmente para generar los archivos de salida.
7. **Subir todos los archivos** al repositorio y realizar al menos **3 commits** con mensajes claros (ej. "agregué script de limpieza", "corregí etiquetas de factores", "añadí gráfico de coeficientes").
8. **Compartir el enlace** del repositorio en la plataforma del curso (foro o tarea).

Criterios de evaluación:

- ❖ Estructura de carpetas correcta.
- ❖ README completo (objetivo, instrucciones, licencia).
- ❖ Scripts funcionales (al ejecutarlos en orden reproducen los resultados).
- ❖ Commits con mensajes descriptivos.
- ❖ Los archivos generados (tablas, figuras) están en las carpetas correspondientes.

5. Preguntas de reflexión (para foro asincrónico)

1. ¿Qué ventajas tiene usar GitHub en lugar de compartir archivos por correo electrónico?
2. ¿Cómo manejarías una situación en la que los datos son confidenciales y no pueden publicarse?
3. ¿Qué harías si encuentras un error en tu script después de haberlo subido a GitHub?